# Συστήματα Ανάκτησης Πληροφοριών

Φάση 3 – Πιθανοτικό και Γλωσσικό Μοντέλο Ανάκτησης

Στυλιανή Δούκα – p3170042 Βασίλειος Μπάλλας – p170115

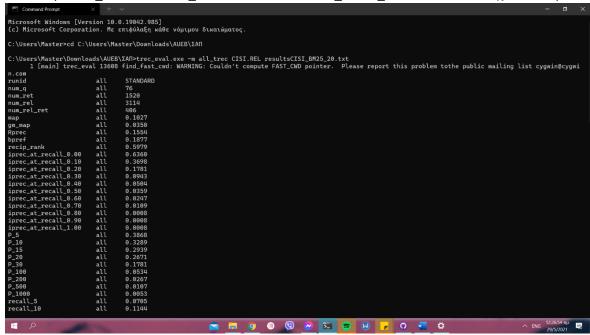
### Περιγραφή Υλοποίησης

Για τις ανάγκες αυτής της Φάσης της εργασίας αλλάξαμε τον τύπο της κλάσης Ομοιότητας πρωτα σε BM25Similarity και έπειτα σε LMJelinekMercerSimilarity.

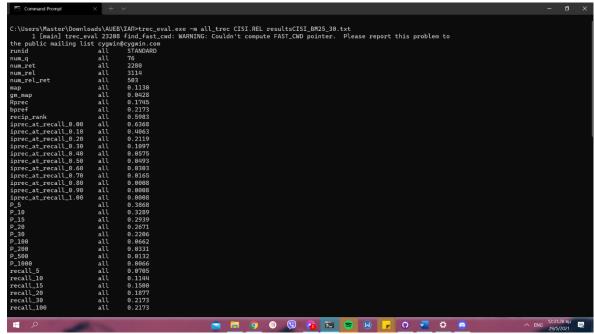
```
// Access the index using indexReaderFSDirectory.open(Paths.get(index)
IndexReader indexReader = DirectoryReader.open(FSDirectory.open(Paths.
IndexSearcher indexSearcher = new IndexSearcher(indexReader);
indexSearcher.setSimilarity(new BM25Similarity());
indexSearcher.setSimilarity(new LMJelinekMercerSimilarity(0.7f));
```

Στη συνέχεια περάσαμε τα αποτελέσματα από το Trec eval:

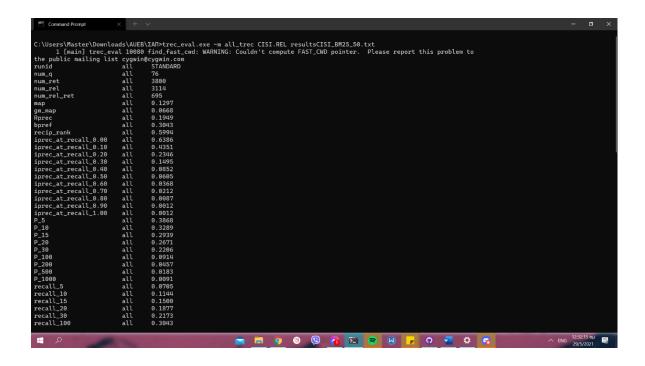
Εκτελούμε trec\_eval.exe -m all\_trec CISI.REL resultsCISI\_BM25\_20.txt στα 20 πιο σχετικά κείμενα



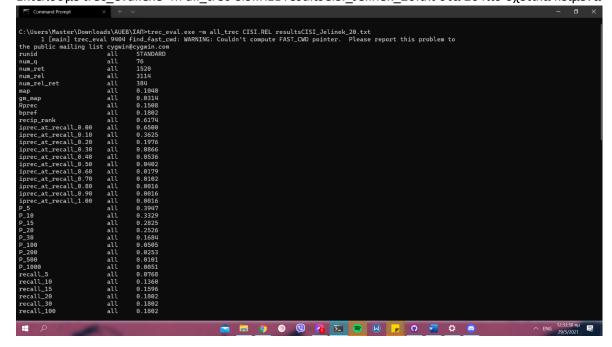
Εκτελούμε trec\_eval.exe -m all\_trec CISI.REL resultsCISI\_BM25\_30.txt στα 30 πιο σχετικά κείμενα



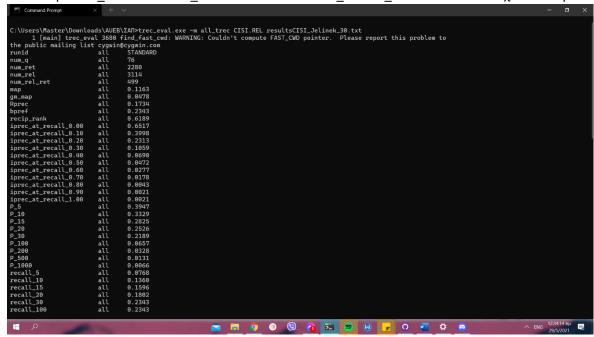
Εκτελούμε trec\_eval.exe -m all\_trec CISI.REL resultsCISI\_BM25\_50.txt στα 50 πιο σχετικά κείμενα



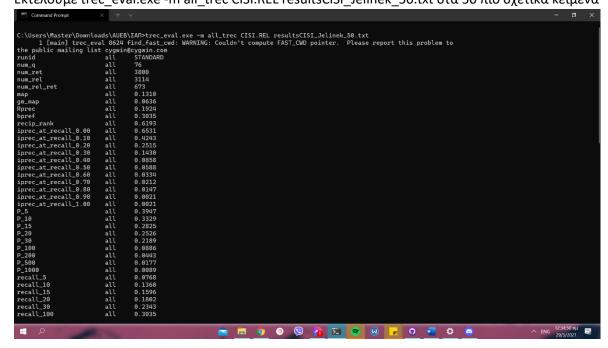
#### Εκτελούμε trec eval.exe -m all trec CISI.REL resultsCISI Jelinek 20.txt στα 20 πιο σχετικά κείμενα



#### Εκτελούμε trec\_eval.exe -m all\_trec CISI.REL resultsCISI\_Jelinek\_30.txt στα 30 πιο σχετικά κείμενα



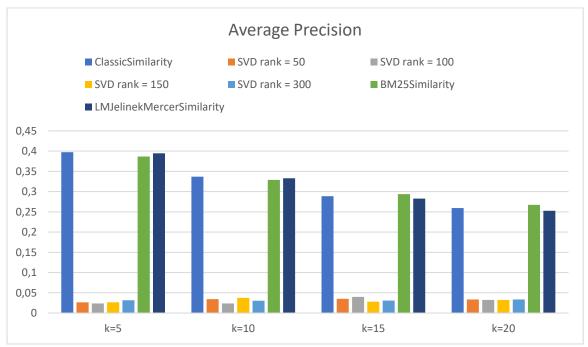
## Εκτελούμε trec\_eval.exe -m all\_trec CISI.REL resultsCISI\_Jelinek\_50.txt στα 50 πιο σχετικά κείμενα



# Σύγκριση με προηγούμενες Φάσεις

## **Average Precision**

	k=5	k=10	k=15	k=20
ClassicSimilarity	0,3974	0,3368	0,2886	0,2592
SVD rank = 50	0,0263	0,0342	0,0351	0,0336
SVD rank = 100	0,0237	0,0237	0,0398	0,0322
SVD rank = 150	0,0263	0,0376	0,0281	0,0322
SVD rank = 300	0,0316	0,0303	0,0307	0,0336
BM25Similarity	0,3868	0,3289	0,2939	0,2671
LMJelinekMercerSimilarity	0,3947	0,3329	0,2825	0,2526

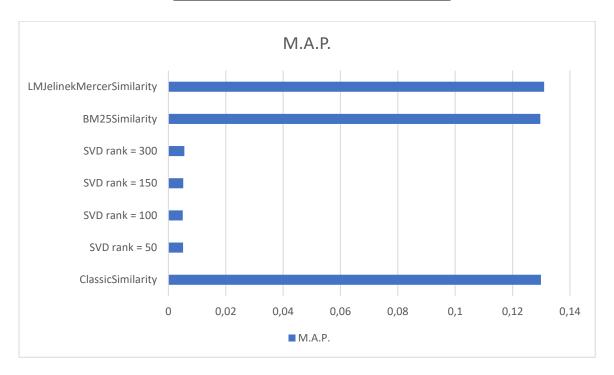


Παρατηρούμε ότι ο SVD βγαζει πολύ χειρότερα αποτελέσματα από τις κλάσεις ομοιότητας. Οι κλάσεις που χρησιμοποιήσαμε στη Φάση 3 έχουν παρόμοια αποτελέσματα με την ClassicSimilarity που χρησιμοποιήσαμε στην Φαση 1.

Παρόμοια είναι και η κατάσταση στο Μ.Α.Ρ.:

# **Mean Average Precision**

	M.A.P.
ClassicSimilarity	0,1299
SVD rank = 50	0,0051
SVD rank = 100	0,0050
SVD rank = 150	0,0052
SVD rank = 300	0,0056
BM25Similarity	0,1297
LMJelinekMercerSimilarity	0,1310



## Πηγές:

https://lucene,apache.org/core/8\_0\_0/core/org/apache/lucene/search/similarities/LMJelinekMercerSimilarity.html